



i-VisionGroup@Tsinghua

文献阅读


谭子萌

Dataset

2015 ISBI Challenge

400张颅骨X光数据（其中150train 250test）

1935×2400, $0.1 \times 0.1\text{mm}^2$, 19个关键点标注



(c) Lateral Cephalograms

Locating Cephalometric X-Ray Landmarks with Foveated Pyramid Attention

Motivation



1. 人只关心视网膜中心凹处的小部分区域，远离焦点的像素呈指数减少。
- CNN均匀采样的策略：高分辨率图像计算量大、内存占用大；低分辨率图像会显著影响检测精度。

Contribution

1. 围绕焦点的非均匀采样：图像金字塔
2. 错误反馈：迭代估计关键点坐标

Foveated Pyramid Attention

1. Input: 对原图进行下采样 2^i 。以焦点为中心采样相同大小的patch $N \times 64 \times 64$
2. 初值选取: train: 在训练集拟合的高斯分布上采样;
test: 直接使用训练集的均值位置。




Model

1. CNN: 以图像金字塔 $N \times 64 \times 64$ 为输入, 输出低分辨率热图A: $N \times 256 \times 8 \times 8$
2. A \rightarrow softmax \rightarrow P. 以可导求期望的方式由热图计算坐标 $\in [-1, 1]$, F: $N \times 256 \times 3$

$$\mathbf{f}_k = \begin{bmatrix} f_{kx} \\ f_{ky} \\ f_{ka} \end{bmatrix} = \sum_{y=1}^{H=8} \sum_{x=1}^{W=8} p_k(x, y) \begin{bmatrix} (x - 4.5)/4 \\ (y - 4.5)/4 \\ A_k(x, y) \end{bmatrix}$$

3. F \rightarrow flatten \rightarrow S: $N \times 768 \rightarrow$ 3层MLP \rightarrow 此阶段的偏移量 \bar{x} , $\hat{\mathbf{x}}_{t+1} = \hat{\mathbf{x}}_t + \bar{\mathbf{x}}_t$



L1 loss: scale-free 梯度大小只与方向有关。所有尺度以大致相同的速率学习。

Algorithm 1: Procedure for a Single Image

Input: Image \mathbf{X}

Output: Estimated Landmark Location $\hat{\mathbf{x}}$

μ = mean landmark position and σ = standard deviation from the training set

if *training* **then**

 Initialize initial location estimate: $\hat{\mathbf{x}} \sim \mathcal{N}(\mu, \sigma)$

else

 Initialize initial location estimate: $\hat{\mathbf{x}} \leftarrow \mu$

end

Initialize Gaussian Pyramid \mathbf{I} with N levels from image \mathbf{X}

for $t \leftarrow 1$ **to** 10 **do**

 Initialize an empty vector of spatialized features \mathfrak{s}

for $i \leftarrow 1$ **to** N **do**

 Crop a zero padded 64×64 glimpse patch g_i from pyramid level I_i centered on $\hat{\mathbf{x}}$

 Process g_i with the CNN to produce a $C \times H \times W$ activation volume \mathbf{A}

 Spatialize the channels of \mathbf{A} into a flat $3 \times C$ vector \mathbf{s}_i of C spatialized features

 Append \mathbf{s}_i to \mathfrak{s}

end

 Process \mathfrak{s} with the MLP to produce an offset estimate $\bar{\mathbf{x}}$

 Update the current location estimate: $\hat{\mathbf{x}} \leftarrow \hat{\mathbf{x}} + \bar{\mathbf{x}}$

if *training* **then**


 Backpropagate the ℓ_1 error of the label \mathbf{x} and the current estimate: $\|\mathbf{x} - \hat{\mathbf{x}}\|_1$

end

end

Train

CNN: ResNet结构, 在ImageNet上做预训练



Structured Landmark Detection via Topology-Adapting Deep Graph Learning

Motivation

1. 热图方法的主要缺点：没有考虑形状/结构约束

直接回归坐标的方法具备整合结构知识的潜力（使用训练集均值做初始化其实间接地注入弱结构知识）

2. 手工定义点间关系/分组会引入主观因素，导致表现次优

Contribution

1. 空间结构先验 + 局部图像特征

2. 减少手工定义关键点之间关系的需要，使方法用于不同任务


3. 引入形状特征，可在外观有较大变化（如遮挡）时保持高鲁棒性

Cascaded GCN

Global-to-local cascaded Graph Convolutional Networks

1. Global transformation of landmarks: 初值mean shape

2. Local refinement: 局部迭代偏移



Two-cascade GCN

无向图: $G=(V, E, F)$

$V=\{v_i\}$: 关键点 $E=\{e_{ij}\}$: 学习到的点之间的联系 $F=\{f_i\}$: 特征

$$\mathbf{f}^i \leftarrow \mathbf{W}_1 \mathbf{f}^i + \sum_j e_{ij} \mathbf{W}_2 \mathbf{f}^j$$

特征集 $F=\{f_i\}$:

1. 局部图像信息: 从CNN中得到D维特征图H在每个坐标位置上 v_i 的插值

$$\mathbf{p}_i \in R^D$$

2. 全局形状信息: 与其他所有关键点间的偏移量 (flattened)

$$\mathbf{q}_i = \{\mathbf{v}_j - \mathbf{v}_i\}_{j \neq i} \in R^{2 \times (N-1)}$$

3. concat $\mathbf{f}_i \in R^{D+2(N-1)}$.

Global Transformation GCN

透视变换, L1 loss

$$M = [a, b, c, d, e, f, g, h, i]^T \in \mathbb{R}^{9 \times 1}$$

$$\begin{bmatrix} x' \\ y' \\ 1 \end{bmatrix} \cong \begin{bmatrix} rx' \\ ry' \\ r \end{bmatrix} = \begin{pmatrix} a & b & c \\ d & e & f \\ g & h & i \end{pmatrix} \begin{bmatrix} x \\ y \\ 1 \end{bmatrix}$$

对 $\{\mathbf{m}_i\}$

$$\mathbf{M} = \frac{1}{N} \sum_i \mathbf{m}_i,$$

对齐后的关键点坐标

$$V^1 = \{\mathbf{v}_i^1\} = \{\mathbf{M}\mathbf{v}_i^0\}$$

Local Refinement GCN

与global GCN区别仅在于最后一层输出为二维向量


$$\Delta \mathbf{v}_i^t = (\Delta x_i^t, \Delta y_i^t)$$

$$\mathbf{v}_i^{t+1} = \mathbf{v}_i^t + \Delta \mathbf{v}_i^t,$$

迭代多次 T=3

Results

Dataset: 3个人脸数据集（带遮挡）+ 3个x光数据集





i-VisionGroup@Tsinghua

谢谢大家!